

机器学习统计基础习题P1——测试心理学现象


前提条件：

自变量：文字语义与其打印颜色的匹配程度

因变量：说出所有文字打印颜色的时间

检测类型：相依样本（一个人在不同条件下进行两种测试，两种测试相依，个体之间相互独立）、t检验（从可视化直方图中可以看出两种测试大致是正态分布的，两次测试来自的总体呈现正态分布；抽样数量比较大，可以假设抽样数据能估计总体；由于是同一个人的两次测试，两次测试的总体方差可以认为是相等，个体之间是相互独立的；题干中无法得知总体的均值和标准误差，能拿到的分析对象只有样本，从样本估计总体，z分布是知道了总体的均值和标准误差的前提下进行检验；）、双尾检验

可视化



结论：一致文字条件下大部分测试用时小于20；不一致文字条件下大部分测试用时大于20

数学假设：

μ_1 : 一致文字条件下说出所有文字打印颜色的时间的总体均值

μ_2 : 不一致文字条件下说出所有文字打印颜色的时间的总体均值

\bar{x}_1 : 一致文字条件下说出所有文字打印颜色的时间的样本均值

\bar{x}_2 : 不一致文字条件下说出所有文字打印颜色的时间的样本均值

σ_{x_1} : 一致文字条件下说出所有文字打印颜色的时间的样本标准偏差

σ_{x_2} : 不一致文字条件下说出所有文字打印颜色的时间的样本标准偏差

检验过程：

检测条件

$H_0: \mu_1 = \mu_2$ (一致文字和不一致文字的检测时间相同)

$H_1: \mu_1 \neq \mu_2$ (一致文字比不一致文字的检测时间少)

在 $\alpha = 0.05$ 水平下进行统计检验

检测结论

样本数量 $n = 24$

自由度 $df = 24 - 1 = 23$

$$\bar{X}_1 = 14.05 \quad \sigma_{x_1} = \sqrt{\frac{\sum_{i=1}^{24} (X_{1i} - \bar{X}_1)^2}{df}} = 3.56 \text{ (其中, } X_{1i} \text{ 表示抽样 } X_1 \text{ 中的第 } i \text{ 个元素)}$$

$$\bar{X}_2 = 22.02 \quad \sigma_{x_2} = \sqrt{\frac{\sum_{i=1}^{24} (X_{2i} - \bar{X}_2)^2}{df}} = 4.8 \text{ (其中, } X_{1i} \text{ 表示抽样 } X_1 \text{ 中的第 } i \text{ 个元素)}$$

假设两个样本的差异所表示的样本记为 D , 其中单个元素表示为 $D_i (i \in [1, 24])$

则 $\bar{D} = \bar{X}_1 - \bar{X}_2 = -7.97$

$$\text{则 } D \text{ 的标准偏差 } S_d = \sqrt{\frac{\sum_{i=1}^{24} (D_i - \bar{D})^2}{df}} = 4.86$$

$$\text{则 } t_{\text{statistic}} = \frac{\bar{D}}{S_d / \sqrt{n}} = -8.03$$

则差异样本 P 值 $P_{\text{statistic}} \approx 0$

$$\text{Cohen's } d = \frac{\bar{D}}{S_d} = -1.64$$

$$\text{差异 } D \text{ 的标准误差 } SE = \frac{S_d}{\sqrt{n}} = 0.99$$

$\alpha = 0.05$, $df = 23$, 双尾 $t_{\text{临界值}} = \pm 2.069$

置信区间 $[\bar{D} - 2.069 * SE, \bar{D} + 2.069 * SE]$, 即 $[-10.01, -5.92]$

$$\because t_{\text{statistic}} < t_{\text{临界值}}$$

$$\therefore P_{\text{statistic}} < \alpha$$

\therefore 在 $\alpha = 0.05$ 水平下, 拒绝 H_0 , 一致文字的检测时间比不一致文字的检测时间少

总结:

导致的可能原因是: 文字语义与文字颜色不匹配的情况下, 测试者需要使用思考的时间增加; 增加的时间是清除惯性思维, 重新识别颜色的时间;

类似任务: 石头剪刀布游戏, 改成一定要输;

参考：

概念梳理：<http://blog.csdn.net/zzminer/article/details/8939244>

